



SENTIMENT ANALYSIS



Đặng Phương Nam - 2351050106
Nguyễn Hùng Dũng - 2351050022



1. Giới thiệu về Sentiment Analysis

Sentiment Analysis (**Phân tích cảm xúc**) là một kỹ thuật trong **xử lý ngôn ngữ tự nhiên (NLP)**, giúp nhận diện và phân loại cảm xúc trong văn bản, chẳng hạn như tích cực, tiêu cực hay trung lập.

Ngày nay, các doanh nghiệp đang nắm trong tay lượng dữ liệu khách hàng khổng lồ chưa từng có. Điều này vừa là cơ hội, vừa là bài toán khó: làm sao để phân tích khối dữ liệu văn bản đồ sộ này và chắt lọc ra những thông tin đắt giá, từ đó định hướng cho các quyết định kinh doanh.

Ứng dụng thực tế: Giúp các gian hàng thương mại điện tử tự động phân loại hàng ngàn đánh giá để cải thiện chất lượng phục vụ ngay lập tức.



1. Giới thiệu về Sentiment Analysis

Phương pháp tiếp cận xử lý ngôn ngữ tự nhiên (NLP) và các thuật toán training để máy tính phân tích và giải thích văn bản theo cách tương tự như con người. Xác định, phân loại các từ khoá từ bộ dữ liệu.

Deep Learning (CNN, LSTM, BERT): Áp dụng mạng nơ-ron và học sâu để hiểu ngữ cảnh và ý nghĩa của câu văn tốt hơn.



Machine Learning truyền thống: Sử dụng các thuật toán học máy để phân loại cảm xúc từ văn bản dựa trên dữ liệu huấn luyện (Logistic Regression, Naive Bayes, Support Vector Machine)



1. Giới thiệu về Sentiment Analysis

Kết hợp TF-IDF (Trích xuất đặc trưng) và Logistic Regression

Mô hình siêu nhẹ, tốc độ huấn luyện cực nhanh, chạy tốt trên máy tính thường. Phù hợp và cho độ chính xác rất cao với văn bản ngắn (đánh giá sản phẩm). Đặc biệt dễ dàng giải thích kết quả.




2. Tiền xử lý dữ liệu

2.1 Tổng quan Bộ dữ liệu (Dataset)

Nguồn dữ liệu: Vietnamese sentiment analysis, nhóm tự thu thập

- Tổng số lượng mẫu: 51,401 dòng
- Tập huấn luyện (Train): 41120 câu.
- Tập kiểm thử (Test): 10281 câu.

Phân bố nhãn train:



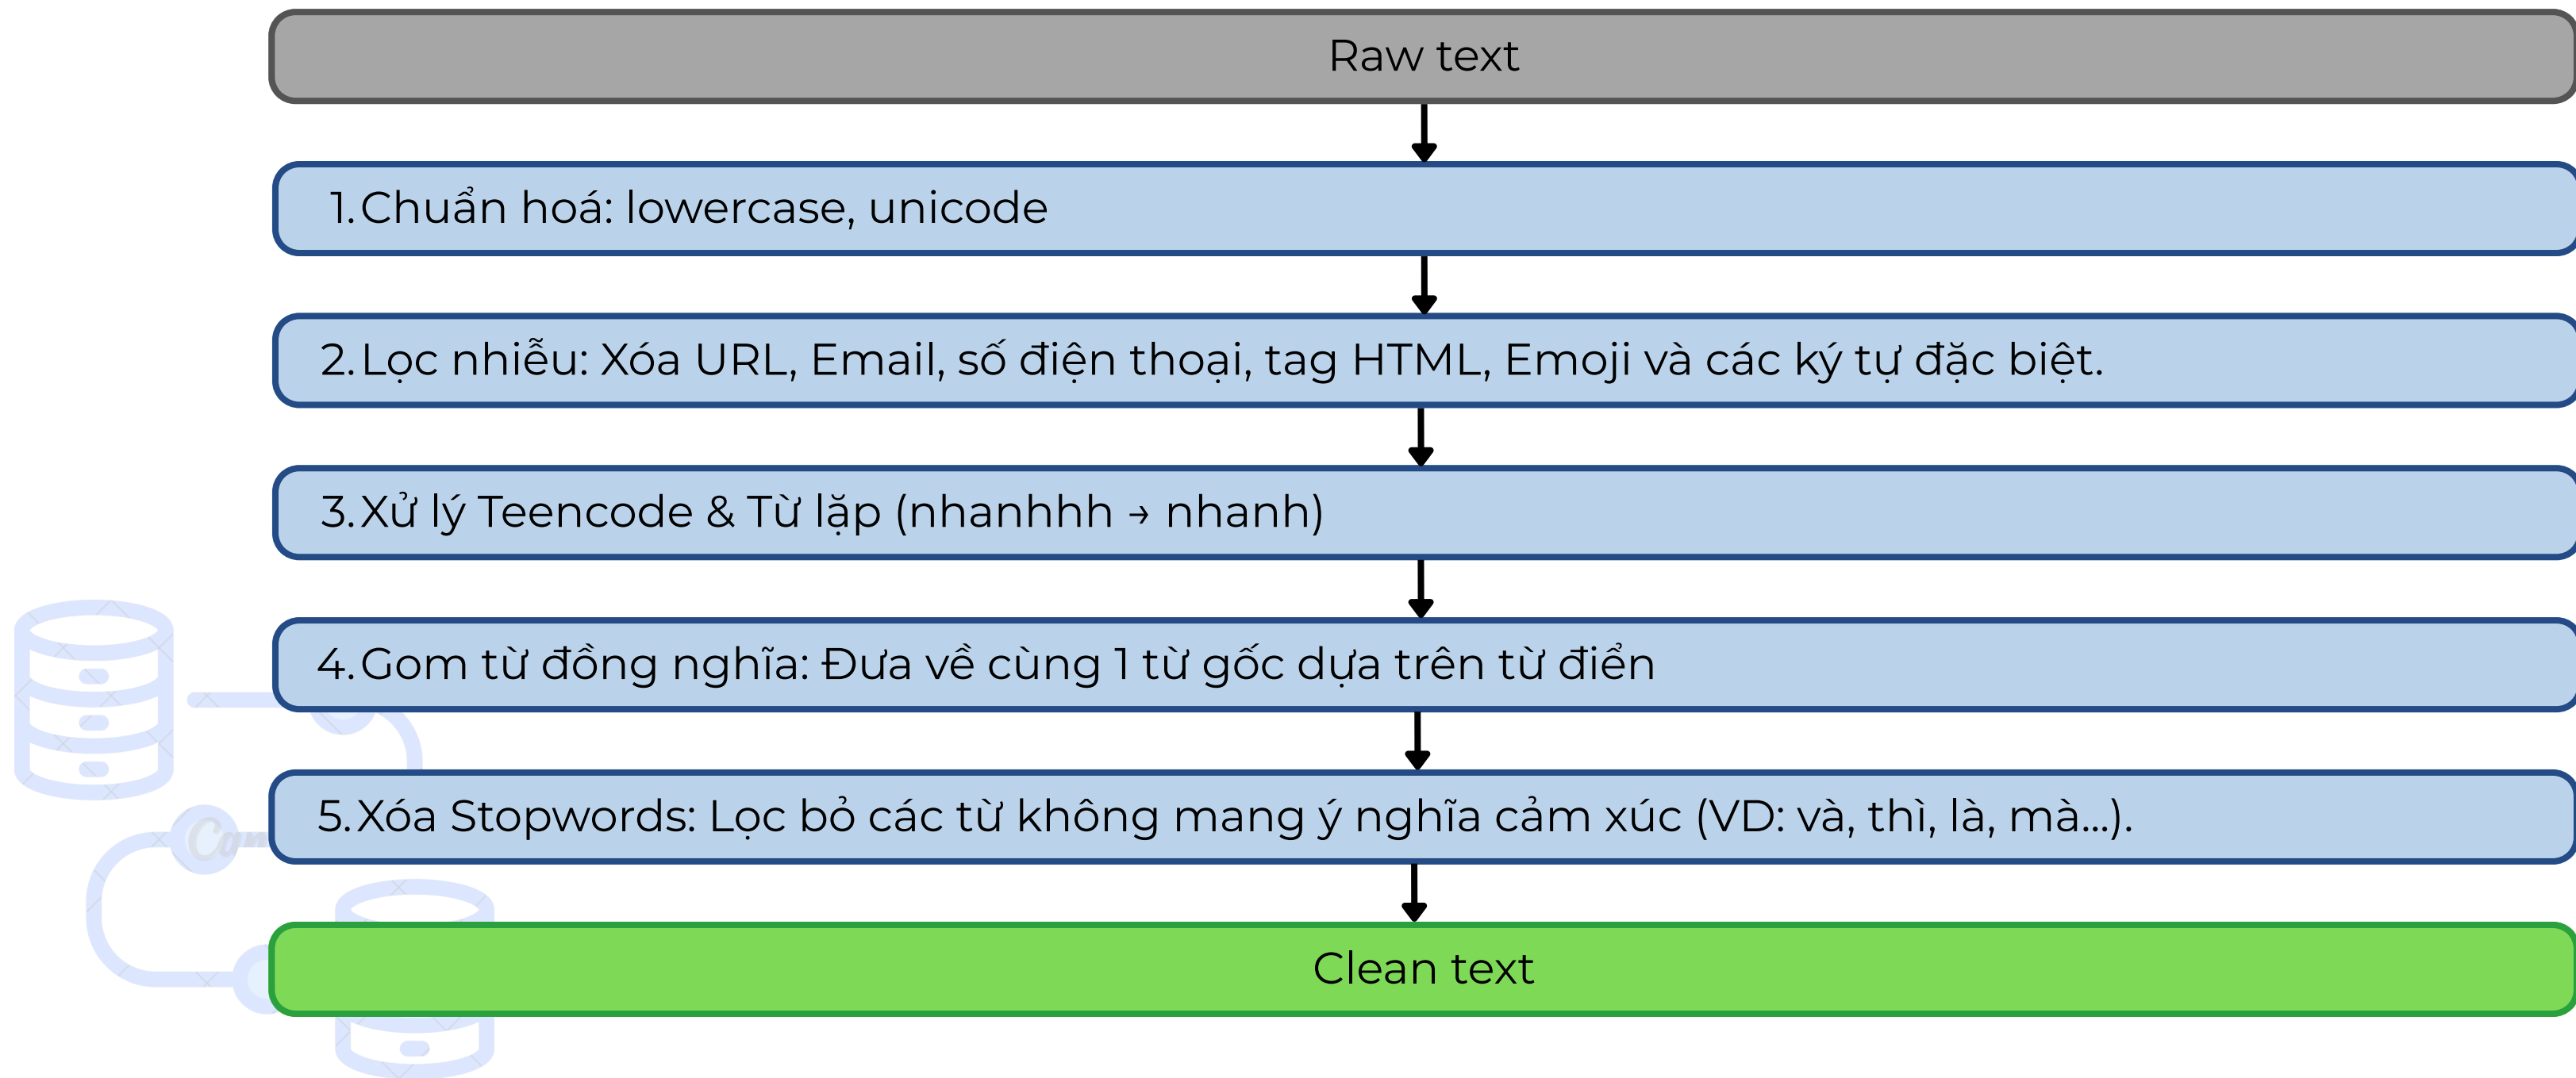
NEU: 11758



POS: 16007

2. Tiền xử lý dữ liệu


2.2 Quá trình làm sạch dữ liệu (Tiền xử lý)



2. Tiền xử lý dữ liệu

2.2 Quá trình làm sạch dữ liệu (Tiền xử lý)

Văn bản gốc	Sau khi xử lý
Hàng freeship ngonnnnn, ko tốn tiền ship v	hàng miễn_phí vận_chuyển ngon không tốn tiền giao_hàng
SDT liên hệ 0901234567 hoặc qua mail test@gmail.com	sdt liên_hệ hoặc mail
Mua máy tính bảng tặng kèm smartphone cực xịn!!!	mua máy_tính bảng tặng kèm smartphone cực xịn
Ghé thăm https://google.com để biết thêm chi tiết #sale	ghé thăm biết thêm chi_tiết
Sản phẩm này rất là tuyệt vời và đĩnhhhhh và xinh đẹp lắm tôi rất vui vẻ	sản_phẩm tốt đĩnh đẹp làm tôi vui



3. Tổng quát về mô hình

3.1 Trích xuất đặc trưng văn bản (TF-IDF Vectorizer)

TF-IDF (viết tắt của Term Frequency - Inverse Document Frequency) là một kỹ thuật thống kê rất phổ biến trong xử lý ngôn ngữ tự nhiên (NLP) và tìm kiếm thông tin. Mục đích của nó là định lượng tầm quan trọng của một từ trong một tài liệu so với một tập hợp các tài liệu.

TF-IDF là công cụ giúp "lọc nhiễu", biến những từ ngữ vô nghĩa thành những con số có trọng số, giúp máy tính hiểu được "từ khóa" nào mới là thứ thực sự quan trọng trong một văn bản.




3. Tổng quát về mô hình

3.2 Huấn luyện với Logistic Regression

Hồi quy logistic là một thuật toán máy học có giám sát được sử dụng cho các vấn đề phân loại. Không giống như hồi quy tuyến tính, dự đoán các giá trị liên tục, nó dự đoán xác suất đầu vào thuộc về một lớp cụ thể



- Nhận các đặc trưng đầu vào từ dữ liệu đã trích xuất
- Tính xác suất
- Mô hình sẽ đưa ra quyết định cuối cùng xem dữ liệu sẽ thuộc class nào, ví dụ như positive, negative hoặc neutral






4. Đánh giá

Class	Precision	Recall	F1-score	Support
Tiêu cực	0.88	0.91	0.89	3339
Tích cực	0.86	0.9	0.88	4002
Trung tính	0.85	0.76	0.8	2940
Accuracy			0.86	10281
Macro avg	0.86	0.86	0.86	10281
Weighted avg	0.86	0.86	0.86	10281


4. Đánh giá



4. Đánh giá



4. Đánh giá



5. Hạn chế

Mất mát thông tin từ Emoji

Bỏ qua một nguồn tín hiệu cảm xúc cực mạnh. Icon 🙄 đôi khi mang giá trị "Tiêu cực" rõ ràng hơn cả một đoạn văn dài

nhãn "Trung tính"

Nhãn "Trung tính" thường chứa các câu lấp lửng (VD: "Sản phẩm cũng được"). Việc gán nhãn này cho AI thường xuyên gây ra nhầm lẫn với các nhãn "Tích cực" hoặc "Tiêu cực"

Hạn chế về ngữ cảnh (TF-IDF)

không hiểu được cấu trúc câu hay ngữ cảnh. AI không hiểu được câu mỉa mai ("Giao hàng nhanh thật đấy... nhưng mà 1 tháng mới tới") nhìn vào từ "nhanh" và đánh giá là Tích cực

CẢM ƠN THẦY VÀ CÁC BẠN